



RAGs, agentes e a pesquisa social em transformação

Infraestruturas de linguagem, agência distribuída e os limites epistemológicos da automação.

SUMMER INSTITUTE IN
COMPUTATIONAL SOCIAL
SCIENCE · BRAZIL

Leonardo F. Nascimento

UFBA · Coord. LABHDUFBA

[ORCID 0000-0003-2929-1115](https://orcid.org/0000-0003-2929-1115)

leofn3@gmail.com

Eric Brasil

UNILAB · PPGIHD-UFRRJ · LABHDUFBA

[ORCID 0000-0001-5067-8475](https://orcid.org/0000-0001-5067-8475)

profericbrasil@gmail.com

O percurso da apresentação

01**RAG e Social-RAG**

Recuperação semântica, geração ancorada, arquitetura do pipeline e avaliação comparativa.

02**Agentes na pesquisa**

Modelos com memória e ferramentas, fluxos de trabalho e agência distribuída.

03**Impactos epistemológicos**

Crítica dos dados e das ferramentas, posições do humano no ciclo e limites da delegação.

Do corpus à resposta; da resposta à ação; da ação à responsabilidade.

A pesquisa do LABHDUFBA em escala

Ecossistema multiplataforma de desinformação e radicalização no Brasil: Telegram, YouTube, Instagram, WhatsApp e outras infraestruturas.

+70M

MENSAGENS · 2015–2025

5M

IMAGENS E VÍDEOS

3M

LINKS DO YOUTUBE

30 TB

DE DADOS

Essa escala impôs o desenvolvimento de ferramentas e métodos capazes de articular exploração computacional, rastreabilidade e interpretação qualitativa.

01

RAG: definição e estrutura

Como ancorar a geração de linguagem em evidências recuperáveis.

Como funciona um RAG

01**Indexação**

Documentos viram vetores e são armazenados em uma base preparada para busca por similaridade.

02**Recuperação**

A pergunta localiza passagens semanticamente próximas, mesmo sem coincidência literal.

03**Geração**

O LLM responde condicionado pelas passagens recuperadas e seus metadados.

RAG não garante verdade. Ele cria uma cadeia de evidências que pode ser examinada.

02

Arquitetura do Social-RAG

Um pipeline modular orientado à rastreabilidade e ao uso qualitativo.

Pipeline modular em cinco etapas

01**Vetorização**

text-embedding-3-large
Representação
semântica do corpus.

**02****Indexação**

ChromaDB + HNSW
para busca aproximada
de vizinhos.

**03****Recuperação**

Adaptive-K seleciona
um corte dinâmico na
curva de similaridade.

**04****Reranking**

MMR equilibra
relevância e
diversidade.

**05****Geração**

Prompt analítico e
resposta ancorada nos
trechos.

Stack: Python · LangChain · Ollama · OpenAI API · ChromaDB · pandas · FastAPI · Streamlit.

Do Telegram à resposta auditável

1

Coleta & preparação

Grupos públicos → MTProto/Python → Elasticsearch → recorte temático → normalização e deduplicação.

CSV / JSON

metadados

2

Indexação semântica

Uma mensagem por chunk → embeddings → ChromaDB/HNSW.

message_id

chat_title

strict_date

3

Consulta & geração

Query → top-N → Adaptive-K → MMR → LLM → resposta com trechos citáveis.

prompt

logs

Markdown

A interface sustenta o *human-in-the-loop*; não o elimina.

Dois subconjuntos temáticos do Telegram

116.284

Vacinas

Mensagens únicas desde 2022. Recorte maior, heterogêneo e narrativamente complexo.

3.284

Lei Rouanet

Mensagens únicas desde 2017. Recorte menor, concentrado em enquadramentos de “guerra cultural”.

Os dois recortes testam o sistema sob graus distintos de variabilidade discursiva.

Coleta em grupos e canais públicos · posição lurker · anonimização · não redistribuição do corpus integral.

Três escolhas que sustentam o sistema

1**1 chunk = 1 post**

A mensagem é a unidade mínima, citável e verificável. Dividi-la perderia contexto; agregá-la introduziria ruído.

K**Adaptive-K**

O corte acompanha a distribuição de similaridade, com piso e teto para evitar contextos pobres ou excessivos.

**MMR**

O reranking reduz redundância entre reposts e prioriza passagens relevantes, mas informacionalmente distintas.

Três perfis de implantação

MODELO	NOME	PARÂMETROS	PERFIL
A	gemma3:12b	12B	Local, open-weight, via Ollama. Reprodutibilidade e menor custo operacional.
B	gpt-oss:120b-cloud	120B	Cloud, open-weight, via Ollama. Pesos abertos com maior capacidade.
C	gpt-5-mini	—	Cloud, comercial e fechado, via OpenAI API. Referência otimizada.

Um espectro realista: local e controlável → aberto e escalável → fechado e robusto.

03

Avaliação do sistema

Perguntas hermenêuticas e factuais, julgamento cego por modelos e avaliação humana.

Dois blocos complementares

Hermenêutico

Análise de padrões discursivos, enquadramentos, metáforas, julgamentos morais e associações políticas.

- Acurácia temática
- Profundidade e síntese
- Precisão das evidências
- Sensibilidade política


Factual

Recuperação de entidades, números, datas, valores, links, descrições, negações e ausências.

- Precisão literal
- Cobertura factual
- Extração de entidades
- Ausência de alucinações

LLM-as-judge cego em três rodadas rotacionais · juízes GPT-5 e Gemini Pro · avaliação humana com o mesmo protocolo · 13 tabelas.

Modelos B e C dominam o rigor interpretativo



PADRÃO CONSISTENTE

A direção dos resultados se repete entre temas e juízes.

C ≥ B

gpt-5-mini lidera, com gpt-oss:120b muito próximo.

A FICA ATRÁS

As maiores diferenças aparecem em profundidade, síntese e precisão evidencial.

O bloco factual amplia a distância




Figure 2. Factual Evaluation (by Judge): Vaccine and Rouanet - Criterion-Level Radar Profiles

B E C CONVERGEM

Perfis altos em precisão literal, entidades e sensibilidade a negações.

O GAP AUMENTA

Tarefas de ancoragem literal expõem fragilidades de modelos menores.

USO SITUADO

O modelo A permanece útil para exploração, mas exige cautela na verificação.

A ordenação resiste a severidades distintas




Figure 3. Overall Mean Score Variation: Judge × Subset × Model

DIREÇÃO ESTÁVEL

A ordenação $C \geq B \gg A$ permanece entre juízes e subconjuntos.

ESCALAS DIFERENTES

Gemini julga de modo mais generoso; GPT-5 e humano são mais severos.

VACINAS DISCRIMINAM MAIS

O corpus maior e heterogêneo separa melhor os modelos.

04

Agentes na pesquisa

O que muda quando o modelo ganha ferramentas, memória e capacidade de agir em ciclos.

Um agente planeja, age e revê resultados

Controle

Memória, base de conhecimento, planejamento e critérios de decisão.

storage

planning

reasoning



LLM-agente

Modelo de linguagem + ferramentas + memória + ciclo de feedback.

percepção

ação

ferramentas

feedback

Humano: delega · supervisiona · valida.

Agentes precedem os LLMs. A fusão LLM + agente redefine alcance, interface e distribuição da agência.

Agência distribuída

O pesquisador não é substituído. A agência se redistribui entre pessoas, modelos, ferramentas e infraestruturas.

Delegação situada

Escopo, critérios e ferramentas são definidos para uma tarefa concreta.

Guardrails

Pontos de validação restringem o que pode avançar sem revisão.

Responsabilidade

Autoria e prestação de contas permanecem humanas.

05

Considerações epistemológicas

Crítica dos dados e das ferramentas, lugar do humano e limites de matematizar o sentido.

Por que o humano importa

Crítica dos dados

"Raw data is an oxymoron." Todo dado possui condições de existência e uma história.

Gitelman, 2013 · Brasil & Nascimento, 2020.

Crítica das ferramentas

Ferramentas incorporam teoria, julgamento e escolhas. Erros de código viram erros metodológicos.

Rieder & Röhle, 2012.

Teoria + empiria

Abstração, abdução e indução ligam o trabalho empírico à construção conceitual.

Ignatow, 2020.

Human in · on · out of the loop

IN THE LOOP

No ciclo

A máquina só decide ou age após confirmação humana.

↑ transparência e controle
↓ gargalo humano

ON THE LOOP

Sobre o ciclo

A máquina age sob supervisão. O operador inspeciona e pode interromper ou anular ações.

escala com controle seletivo

OUT OF THE LOOP

Fora do ciclo

Decisão e ação avançam sem entrada ou interação humana.

↑ escala
↓ controle e escrutínio

A posição do humano é uma decisão metodológica dependente do risco. Taxonomia adaptada de Human Rights Watch, *Losing Humanity*, 2012.

É possível matematizar o sentido?

A operação

Embeddings projetam textos em vetores e tornam comparáveis certas regularidades semânticas.

A promessa

Recuperar, agrupar e explorar milhões de registros em uma escala antes inacessível.

O risco

Confundir proximidade estatística com sentido social e apagar o que o vetor não representa.

"A revolução das modalidades de produção e de transmissão dos textos é também uma mutação epistemológica fundamental."

Roger Chartier, 2002, p. 108.

Velhos problemas, novas configurações

Teóricos

Quais conceitos sobrevivem quando objeto e método são reconstituídos digitalmente?

Metodológicos

Como validar, reproduzir e criticar ferramentas compostas por muitas camadas?

Financeiros

Quem financia cômputo, armazenamento, APIs e manutenção de longo prazo?

Epistemológicos

Onde a interpretação, o julgamento e a responsabilidade permanecem indelegáveis?

O futuro da pesquisa computacional já é um problema do presente.

Obrigado.

A pesquisa digital não é apenas automação. É uma reconfiguração de agência, evidência e responsabilidade.

LABHDUFBAlabhdufba.github.io/pt**SOCIAL-RAG**github.com/LABHDUFBA/social-rag**PREPRINT**doi.org/10.31235/osf.io/wmc2q_v1**DADOS / CÓDIGO**doi.org/10.5281/zenodo.18601216**LEONARDO**leofn.com · github.com/leofn · leofn3@gmail.com**ERIC**ericbrasil.com.br · github.com/ericbrasiln · profericbrasil@gmail.com